



Desafio 2 - Segurança com Big Data e IA

Equipe Responsável

Renato Lacerda do Couto

renato_couto@estudante.sesisenai.org

Paulo Victor Aragão dos Santos

paulo_va_santos@estudante.sesisenai.org

Rodrigo Barbosa Pithon

rodrigo_pithon@estudante.sesisenai.org

Junho de 2026

Curso: Graduação em Segurança Cibernética

Turma do 5º Período

RESUMO

O crescimento da transformação digital no setor financeiro ampliou a superfície de ataque, especialmente em APIs e aplicações web acessadas fora do horário comercial. Este trabalho propõe uma arquitetura de segurança cibernética inteligente que integra Big Data, Inteligência Artificial e automação de respostas. A solução utiliza o stack ELK (Elasticsearch, Logstash, Kibana) com Apache Kafka, Wazuh como SIEM, Isolation Forest para detecção de anomalias e TheHive + Cortex como plataforma SOAR. O modelo permite detecção em tempo real de comportamentos anômalos, redução de falsos positivos e resposta automatizada a incidentes. Foram desenvolvidos fluxos de orquestração, protótipo funcional em Python e considerações éticas alinhadas à LGPD e GDPR. Os resultados indicam viabilidade técnica e operacional para empresas de médio e grande porte, contribuindo para a redução do tempo médio de detecção (MTTD) e resposta (MTTR).

Palavras-chave: Segurança cibernética; Inteligência Artificial; Big Data; SIEM; SOAR; Isolation Forest; Wazuh.

1. INTRODUÇÃO

A migração de sistemas críticos para ambientes de nuvem híbrida no setor financeiro tem gerado novos desafios de segurança, uma vez que ataques como brute force, credential stuffing e exploração de APIs fora do horário comercial tornaram-se frequentes, exigindo soluções proativas que vão além de controles tradicionais.

Este relatório apresenta uma proposta de arquitetura de defesa cibernética baseada em Big Data, IA e automação, buscando investigar como integrar ferramentas de Big Data, algoritmos de IA e plataformas SOAR para fortalecer a postura de segurança em instituições financeiras em transformação digital.

O objetivo principal foi o de demonstrar a viabilidade de uma solução integrada capaz de detectar comportamentos anômalos em tempo real e automatizar respostas a incidentes, tendo em vista o fato de que a ausência de correlação inteligente de logs e respostas automatizadas aumenta o risco de violações de dados e prejuízos financeiros.

2. REVISÃO DE LITERATURA

A literatura recente tem destacado a importância da integração entre **SIEM (Security Information and Event Management)**, **Big Data** e **Machine Learning** como abordagem estratégica para a detecção proativa de ameaças cibernéticas (MITRE ATT&CK, 2025; Chio & Freeman, 2023). Essa combinação permite a correlação em tempo real de grandes volumes de dados, superando as limitações dos sistemas baseados apenas em regras estáticas.

Ferramentas open source como o **Wazuh** e o **ELK Stack** (Elasticsearch, Logstash e Kibana) têm se consolidado como soluções maduras e eficazes em ambientes híbridos (on-premise e nuvem), oferecendo escalabilidade, integração nativa e baixo custo de adoção (Wazuh, 2026; Elastic, 2025).

Especificamente, algoritmos de aprendizado não supervisionado, em especial o **Isolation Forest**, têm sido amplamente adotados na detecção de anomalias em logs de autenticação. Sua eficiência computacional, robustez frente a ruídos e capacidade de identificar outliers sem a necessidade de dados rotulados prévios tornam-no particularmente adequado para cenários de segurança cibernética em transformação digital (Liu et al., 2008; Scikit-learn, 2025).


3. METODOLOGIA

A pesquisa é de natureza aplicada e utiliza abordagem de prototipagem. A arquitetura completa proposta (ELK + Apache Kafka + Wazuh + Isolation Forest + TheHive + Cortex) é robusta e adequada para ambiente de produção, porém apresenta alta demanda computacional, tornando sua execução integral em um ambiente local de desenvolvimento complexa.

Por esse motivo, o protótipo funcional desenvolvido concentra-se no módulo de **detecção de anomalias com Isolation Forest**, componente central da solução de IA. O script simula a análise comportamental que seria realizada após o processamento dos logs, sendo totalmente executável em qualquer máquina com Python.

Para facilitar testes locais do ambiente de visualização, foi disponibilizado um arquivo `docker-compose-minimal.yml` contendo Elasticsearch + Kibana. O Wazuh e as demais ferramentas podem ser integrados posteriormente conforme necessidade.

Arquitetura de Segurança Inteligente – IA + Big Data + SOAR



Componentes principais:

- **Coleta e Streaming:** Filebeat, Fluentd e Apache Kafka.
- **Processamento:** Logstash com normalização e remoção de dados sensíveis.
- **Armazenamento:** Elasticsearch com retenção de 12 meses (90 dias em hot storage).
- **Deteção:** Wazuh + modelo Isolation Forest (scikit-learn).
- **Resposta:** TheHive + Cortex (SOAR).

Protótipo foi desenvolvido em Python com Isolation Forest para detecção de logins anômalos (horário, tentativas falhas, IP externo).

Conforme ilustrado na Figura 1, a arquitetura proposta integra coleta de logs em ambientes híbridos, processamento via Apache Kafka e Logstash, detecção de anomalias com Isolation Forest e resposta automatizada através do TheHive e Cortex, com ênfase no monitoramento de APIs críticas

4. DESENVOLVIMENTO E RESULTADOS


4.1 Resultados do Protótipo

Script disponível em:

https://colab.research.google.com/drive/1pFWKWQ2lfo-jkknZt4nyC7WpvhA_Kw8-

Ao executar o script `isolation\_forest\_prototype.ipynb`, o modelo identificou corretamente as anomalias injetadas, demonstrando eficácia na detecção de acessos fora do horário comercial com múltiplas falhas.

Detecção de Anomalias – Isolation Forest



Exemplo de anomalias detectadas

```
# ===== SALVAR RESULTADOS =====  
data.to_csv('resultados_anomalias_logins.csv', index=False)  
print("\nResultados salvos em 'resultados_anomalias_logins.csv'")
```

... Total de amostras: 5000

Anomalias injetadas: 80

Anomalias detectadas: 100

Exemplos de anomalias detectadas:

	hour	failed_attempts	external_ip	anomaly_score
165	5	5	0	-0.015041
756	20	4	0	-0.000798
1204	1	5	0	-0.009556
1373	9	4	0	-0.001680
1489	6	4	1	-0.004537
2320	22	6	1	-0.005263
2371	8	4	0	-0.002781
2376	6	4	0	-0.010786
2460	0	4	0	-0.008956
2565	3	5	0	-0.007314

O código completo, o dataset gerado e o README detalhado estão disponíveis no repositório Git do projeto.

4.1.2 Algoritmo de Detecção

O algoritmo Isolation Forest foi escolhido por ser não supervisionado e adequado ao volume de dados. As features utilizadas incluem: hora cíclica (seno/cosseno), flag de fim de semana, tentativas falhas e origem do IP.

4.2 Fluxo de Resposta Automatizada

1. Detecção (Wazuh + IA)
2. Enriquecimento (Threat Intelligence + Active Directory)
3. Contenção automática (bloqueio de IP, isolamento de endpoint, revoke de tokens)
4. Notificação e feedback para re-treinamento do modelo.

4.3 Considerações Éticas e Conformidade

- Pseudonimização via hash SHA-256 + salt rotativo.
- Auditoria de viés algorítmico.
- Direito de contestação pelo usuário.
- Alinhamento com LGPD (art. 7º, IX) e GDPR.

Protótipo funcional: Disponível no repositório Git:

https://github.com/paulovasantos-cmyk/seguranca-ia-bigdata/blob/main/isolation_forest_prototype.ipynb

O protótipo gera um conjunto de dados sintéticos com 5.000 registros, injeta anomalias realistas e aplica o modelo de detecção, produzindo como saída um arquivo `dados\_sinteticos.csv` e visualizações gráficas.

5. CONCLUSÃO

A arquitetura proposta demonstrou ser viável, escalável e alinhada às necessidades de instituições financeiras. A integração de Big Data, IA e SOAR permite uma postura de segurança proativa, com redução esperada de MTDD e MTTR. Como trabalhos futuros, sugere-se a implementação em ambiente controlado e a incorporação de modelos de IA generativa (LLM) para análise investigativa.

REFERÊNCIAS

(Conforme ABNT NBR 6023)

BRASIL. Lei nº 13.709, de 14 de agosto de 2018. Lei Geral de Proteção de Dados Pessoais (LGPD).

MITRE. MITRE ATT&CK Framework. 2025. Disponível em: <<https://attack.mitre.org/>>. Acesso em: 14 jun. 2026.

SCIKIT-LEARN. Isolation Forest. Documentação oficial.

WAZUH. Wazuh Documentation. 2026.

ELASTIC. Elasticsearch: The Official Guide.

(Complete com mais referências conforme necessário)

